

Ti6554 钛合金低温力学性能及机器学习预测模型

刘传焜, 曲周德*, 武川

(天津职业技术师范大学 a.汽车模具智能制造技术国家地方联合工程实验室
b.天津市高性能精准成形制造技术与装备重点实验室, 天津 300222)

摘要: **目的** 研究 Ti6554 钛合金在低温环境下的力学行为及组织演变, 揭示温度对其力学性能的影响机制。**方法** 利用液氮结合拉伸实验获取载荷-位移曲线, 并通过真应力-真应变分析、断口观察、加工硬化率测定及 EBSD 表征进行深入分析, 同时构建了支持向量回归-粒子群优化算法模型 (PSO-SVR) 和 EBP 神经网络预测模型。**结果** 随着温度降低, 合金应力显著升高, 孪晶与位错的交互作用强化了屈服强度但导致延伸率下降, 在 0~−180 °C 区间内, 断裂方式由韧性断裂逐渐转变为韧性混合断裂。模型精度评估结果表明, PSO-SVR 模型最优 R^2 为 0.94, RMSE 平均值为 11.12 MPa, MAE 平均值达到 9.024 MPa; EBP 模型最优 R^2 高达 0.98, RMSE 的平均值为 4.01 MPa, MAE 平均值为 2.067 MPa, 展现的性能更优。**结论** 低温显著提升了材料的屈服强度与抗拉强度, 其根本原因在于原子间结合力增强, 导致位错滑移需克服的晶格摩擦阻力更高, 同时原子热运动减弱, 使位错难以获得足够能量克服障碍。然而, 这种强化伴随塑性下降、延伸率降低。随着拉伸温度从 0 °C 降低至 −180 °C, 合金的主导断裂机制由韧性断裂转变为韧性混合断裂。EBP 神经网络预测模型预测精度显著优于支持向量回归-粒子群优化算法模型 (PSO-SVR) 的预测精度。

关键词: 低温钛合金; 力学性能; 支持向量回归 (SVR); 神经网络 (BP)

DOI: 10.3969/j.issn.1674-6457.2026.04.002

中图分类号: TG115.5⁺2; TG146.2 **文献标志码:** A **文章编号:** 1674-6457(2026)04-0011-13

Cryogenic Mechanical Properties and Machine Learning Prediction Model of Ti6554 Titanium Alloy

LIU Chuankun, QU Zhoude*, WU Chuan

(a. National-local Joint Engineering Laboratory of Intelligent Manufacturing Oriented Automobile Die & Mould, b. Tianjin Key Laboratory of High Performance Precision Forming Manufacturing Technology and Equipment, Tianjin University of Technology and Education, Tianjin 300222, China)

ABSTRACT: The work aims to study the mechanical behavior and microstructural evolution of Ti-6554 titanium alloy subject to cryogenic conditions, elucidating the underlying mechanisms governing temperature-dependent property variations. Load-displacement curves were captured via a liquid nitrogen-integrated tensile testing apparatus, while temperature-dependent mechanisms governing mechanical properties were probed through comprehensive analysis of true stress-strain curves, fracto-

收稿日期: 2025-11-12

Received: 2025-11-12

基金项目: 国家自然科学基金 (52475394, 52075386); 天津市自然科学基金多投入重点项目 (22JCZDJC00650)

Fund: National Natural Science Foundation of China (52475394, 52075386); Tianjin Natural Science Foundation of China-Multi-input Key Projects (22JCZDJC00650)

引文格式: 刘传焜, 曲周德, 武川, 等. Ti6554 钛合金低温力学性能及机器学习预测模型[J]. 精密成形工程, 2026, 18(4): 11-23. LIU Chuankun, QU Zhoude, WU Chuan. Cryogenic Mechanical Properties and Machine Learning Prediction Model of Ti6554 Titanium Alloy[J]. Journal of Netshape Forming Engineering, 2026, 18(4): 11-23.

*通信作者 (Corresponding author)

graphic observations, work hardening rate quantification, and electron backscatter diffraction (EBSD) characterization. Based on these findings, a Support Vector Regression optimized by Particle Swarm Algorithm (PSO-SVR) and an Error Back-Propagation neural network model (EBP) were formulated. Experimental outcomes revealed that progressive temperature reduction induced significant flow stress elevation of Ti-6554 titanium alloy, where twin-dislocation interactions were found to enhance yield strength yet diminish elongation. Crucially, a fracture mode transition from ductile to ductile-brittle mixed failure was documented across the 0 °C to -180 °C regime. Model validation demonstrated optimal R^2 values of 0.94 and 0.98 for PSO-SVR and EBP respectively, with corresponding mean RMSE of 11.12 MPa and 4.01 MPa, and mean MAE of 9.024 MPa and 2.067 MPa, conclusively establishing the superior predictive capability of the EBP framework. Cryogenic temperatures substantially enhance both the yield strength and ultimate tensile strength of the material. This strengthening is fundamentally attributed to increased interatomic bonding forces, which elevates the lattice friction resistance that dislocation slip must overcome, coupled with the diminished thermal activation energy available for dislocations to surmount obstacles. However, this strengthening is accompanied by degradation in plasticity, manifested as reduced elongation. As the tensile temperature decreases from 0 °C to -180 °C, the alloy's dominant fracture mechanism shifts from ductile fracture to a ductile-brittle mixed fracture. The developed EBP neural network prediction model demonstrates significantly superior predictive accuracy compared to the PSO-SVR model.

KEY WORDS: cryogenic titanium alloys; mechanical properties; support vector regression (SVR); error back propagation neural network (EBP)

Ti6554 (Ti-6Cr-5Mo-5V-4Al) 钛合金是一种高强度韧性的亚稳定近 β 型钛合金, 具备高比强度、低密度及无磁性等特点^[1-3]。然而, 在涉及低温与载荷的应用场景中, 钛合金作为紧固件等关键部件面临严峻挑战^[4-5]。Ti6554 钛合金作为亚稳 β 钛合金, 在这种应用场景中, 为了确保材料的稳定性与耐久性, 其实验温度范围设定为 0~-180 °C。这一温度范围有效地模拟了实际的温度, 确保这些苛刻条件下紧固件的性能极限得到测试。

由以往的研究可知, 服役温度对钛合金的力学性能起着至关重要的作用^[6-7]。Yao 等^[8]研究表明, Ti-15Mo 合金在 20 K 下拉伸时具有 1 725 MPa 的强度和 10% 的延伸率, 测到锯齿状拉伸曲线和多个颈缩。Di 等^[9]探究了 Ti-6Al-4V 合金在 20 K 下的变形机制并发现了 3 种不同的孪生机制。Zang 等^[10]对亚稳态 β 钛合金在低温下的拉伸性能和变形行为进行了研究, 发现其在 77 K 和 20 K 下分别具有 1 535 MPa 和 1 725 MPa 的超高抗拉强度, 但在 20 K 下延伸率显著下降, 在 77 K 下, 应变硬化率较高, 这归因于孪生, 20 K 下的锯齿状变形是孪生和位错滑移的间歇性激活及热物理激活共同作用的结果。Huang 等^[11]发现低温轧制钛合金中孪生系统和变体的演变主要受初始晶粒取向控制。此外, 有研究表明^[12], 适量添加 β 稳定元素能提升钛合金对裂纹扩展的抵抗力, 这表明钛合金的成分设计和微观组织调控对其力学性能有着显著影响。钛合金在低温条件下的塑性变形过程对应变、温度和应变速率表现出显著的敏感性^[13-14], 这些参数的变化会显著影响钛合金的流变应力和变形机制。然而, 由于流变应力与工艺参数之间存在复杂的非线性关系, 传统的回归数学模型难以准确描述这一现象。因此为精确表征钛合金在低温环境下的变形机制与

特性, 本构方程被广泛应用。但其在处理复杂非线性关系时的局限性促使研究者探索新的方法。在此背景下, 支持向量机和神经网络因其对高维数据和非线性问题的处理优势而受到关注。支持向量机展现出对高维数据、非线性问题的处理优势^[15-18], 神经网络具有强大的学习能力、非线性映射能力、泛化能力^[19-23]。赵文娟等^[24]利用人工神经网络成功反映了 TC21 合金塑性变形过程中流动应力的变化规律。Song^[25]基于 Arrhenius 方程、神经网络和支持向量回归 3 种算法的本构建模, 发现神经网络和支持向量回归 2 种算法预测流动应力的准确性优于 Arrhenius 方程, 支持向量回归算法的计算效率更高。Hussain 等^[26]综述了机器学习在材料非线性本构等建模中的应用, 比较了人工神经网络、支持向量机等方法的优缺点, 发现机器学习能有效处理复杂材料行为。Liu 等^[27]比较了 Arrhenius 与 PSO-SVR 模型预测精度, 发现 PSO-SVR 模型的预测精度更优。Jang 等^[28]提出基于机器学习的塑性本构模型, 通过单元素和多元素模拟验证, 得到了高精度且提升了计算效率。Qiao 等^[29]比较了 Arrhenius 方程和 BP 神经网络模型的预测能力, 发现 BP 神经网络模型精度更高 (相关系数 $(0.995 \pm 1)\%$, 误差达 68.75%), 能更准确预测流动应力变化。有的学者^[30-33]研究表明, 基于 BP 神经网络的模型在预测合金流动应力方面具有显著优势。这些模型通常展现出极高的相关系数 (0.992~0.999), 平均相对误差多低于 1%, 远超传统方法, 充分证实了 BP 神经网络模型在合金变形预测中的高效性与准确性。

本研究对 Ti6554 钛合金在低温环境下的显微组织与低温力学性能进行了分析。基于真应力-真应变曲线, 揭示了拉伸应力随温度的变化规律。基于断口形貌、加工硬化率和微观组织分析, 揭示了低温下

Ti6554 钛合金应力与变形机理的内在关系。基于 7 组温度下的拉伸实验数据和 JC 本构方程的数学表征, 构建了机器学习预测框架, 在支持向量回归本构模型基础上加入了粒子群优化算法, 在 BP 神经网络模型基础上加入了动量项和自适应学习率, 所提方法具有更强的非线性拟合能力, 能精确估算钛合金的流动应力, 为钛合金的有限元仿真分析提供更为精准、可靠的力学性能数据。

1 实验

实验材料为 Ti6554 钛合金棒料, 其化学成分如表 1 所示。本实验采用准静态单轴拉伸法测试该合金的低温力学性能, 实验装置如图 1a 所示。实验过程采用配备液氮制冷系统的微机控制低温拉伸实验机。通过温度控制系统将实验箱的温度精确控制到预设的低温环境。在样品夹紧过程中, 使用低温夹具实现样品的轴向定心固定, 并向伺服加载系统施加轴向拉伸载荷。在拉伸实验过程中, 温度传感器位于绝缘箱内, 实时监测温度, 以确保精确的温度控制。最后, 通过计算机软件对实验过程中收集的力学性能数据进行分析 and 处理, 生成载荷-位移曲线, 为材料低温性能的研究提供依据。

表 1 Ti6554 钛合金化学成分

Tab.1 Chemical composition of Ti6554 titanium alloy

wt. %

C	Cr	V	Mo	Al	Ti
0.027	6.12	4.96	4.9	4.28	Bal.

本实验以 $\phi 40\text{ mm}\times 300\text{ mm}$ 的 Ti6554 钛合金棒材为初始材料。首先使用 SX-G07123K 箱式炉将棒料加热至 $700\text{ }^{\circ}\text{C}$ 并保温 40 min , 使材料内部温度均匀, 为后续的轧制奠定基础。随后, 采用如图 1b 所示的二辊槽轧机对热透的棒料进行轧制, 轧机凹槽尺寸为 $40.0\sim 7.9\text{ mm}$ 的正方形孔, 如图 1c 所示。在轧制过程中, 棒料每通过一次轧孔就将其旋转 180° , 以改变棒料的受力方向, 改善最终力学性能。轧制工艺以及拉伸件原始组织样貌参考文献[2]。轧制完成后, 采用线切割技术加工拉伸试样, 如图 1d 所示。该试样为工形薄板, 严格按照 GB/T 13239—2006 进行设计和制造。其拉伸方向为试样的纵向, 即平行于轧制纤维流向的方向(原始棒料标距 300 mm , 试样标距 45 mm)。为探究温度差对 Ti6554 钛合金力学性能的影响, 在 $0\sim -180\text{ }^{\circ}\text{C}$ 温度范围内, 以 $30\text{ }^{\circ}\text{C}$ 的温度梯度设立了 7 个实验温度点, 具体实验温度分别为 $0、-30、-60、-90、-120、-150、-180\text{ }^{\circ}\text{C}$ 。在实验过程中, 拉伸速度设定为 1 mm/min , 并保持恒定, 直至试样断裂。为确保测试结果的可靠性和有效性, 在每个温度条件下均进行了 3 次拉伸实验。

支持向量回归机 (Support Vector Regression, SVR) 是一种基于统计学习理论与结构风险最小化原则的机器学习模型, 用于解决回归任务。该方法以其全局收敛性及出色的泛化能力而著称, 适用于各种函数回归问题的建模与预测。通过确定最优超平面的位置及其两侧的边界超平面 α_1 和 α_2 , 从而精确划定不同类别的决策边界。原理图如图 2a 所示。BP 神经网络, 全称为 Back Propagation Neural Network, 由




图 1 实验设备及试样

Fig.1 Experimental setup and specimen configuration: a) cryogenic tensile testing machine; b) two-roll groove rolling mill; c) groove shape; d) geometric dimensions of test specimen




图 2 SVR 模型的工作原理图 (a) 和 BP 神经网络流程图 (b)
Fig.2 Schematic diagram of the SVR model (a) and flowchart of the BP neural network (b)

Rumelhart 和 McClelland 于 1985 年首次阐述, 是一种采用多层前馈架构的基本神经网络模型, 其原理如图 2b 所示。BP 神经网络由输入层、隐含层和输出层构成, 其中隐含层有一层或者多层, 每一层可以有若干个节点, 层与层之间节点的连接状态通过权重来体现。

在构建 Ti6554 钛合金流动应力预测模型后, 本文采用均方根误差 (RMSE)、回归系数 (R^2) 和平均绝对误差 (MAE) 度量全局预测的准确性。这些评价标准是回归分析中常用的评价指标, 用于度量预测模型输出与实际观测数据之间的平均差异程度。

首先, 计算预测值与真实值的误差, 然后将每个误差值进行平方, 计算均方误差, 如式 (1) 所示。

$$E_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1)$$

最后, 对均方误差进行平方根运算, 得到均方根误差:

$$E_{\text{RMSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

式中: n 为样本总数; y_i 为模型第 i 个数据组的真实值; $\hat{y}_i$ 表示模型第 i 个数据组的预测值。

决定系数 R^2 通常用于评价回归模型的拟合情况, 是模型性能评估中的一个重要指标。计算公式如下:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

式中: $\bar{y}$ 表示真实值的均值。

平均绝对误差 MAE 用于检测预测值和实际值之间的差异, MAE 越小, 说明模型性能越好。评论模型的计算公式如下:

$$E_{\text{MAE}} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (4)$$

2 结果与分析

2.1 低温应力-应变曲线特征

通过拉伸实验得到 Ti6554 钛合金在 7 种不同温度下的拉伸真应力-应变曲线, 如图 3 所示。曲线中出现的多级屈服变形现象, 证实了温度是影响该合金

力学行为的关键因素。随着实验温度由 0 °C 递减至 -180 °C, 材料的屈服强度及抗拉强度表现出连续递增的特征, 而其延伸率则呈现逐级下降的趋势^[34]。在不同温度下, Ti6554 钛合金的屈服强度表现出从 0 °C 时的 962.11 MPa 持续上升的趋势, 直至 -180 °C 时达到 1 559.84 MPa, 增幅达 62%。相应地, 抗拉强度数值从 980.09 MPa 提升至 1 585.56 MPa, 增幅为 61.8%。延伸率从 17.96% 显著下降至 10.15%, 降幅达 77.8%, 结果如表 2 所示。当温度为 0~-180 °C 时, 可以观察到显著的应力分布差异, 具体地, 这一温度序列被划分为 2 个主要区间: 一是 0~-90 °C, 二是 -120~-180 °C, 各区间内应力表现出独特的特征与变化模




图 3 Ti6554 钛合金真应力-真应变曲线
Fig.3 True stress-true strain curves of Ti-6554 titanium alloy

表 2 不同温度下的力学性能
Tab.2 Mechanical properties at different temperatures

Temperatures/ °C	Yield strength/MPa	Tensile strength/MPa	Percentage elongation after fracture/%
0	962.11	980.09	17.96
-30	1 083.84	1 128.28	13.54
-60	1 181.77	1 190.60	12.19
-90	1 264.89	1 278.32	12.99
-120	1 462.47	1 466.63	11.25
-150	1 503.55	1 514.21	10.81
-180	1 559.84	1 585.56	10.15

式。当温度为 0、-30、-60、-90 °C 时, 在真应力-真应变曲线中, 材料经历了从屈服开始、直到断裂前的整个塑性变形阶段, 应力曲线形成稳定应力平台, 单位应变对应的应力增量约 100 MPa, 体现出塑性变形阶段平缓的加工硬化特征。当温度为-120、-150、-180 °C 时, 曲线转变为短促应力斜坡, 单位应变对应的应力增量小于 100 MPa。在-90~-120 °C 下, 出现强度跳跃, 屈服强度跃升 197 MPa, 同时在-120 °C 下, 屈服强度与抗拉强度差值缩小至 4.2 MPa。在低温下, 随着温度下降, 材料的应力逐渐提升, CRSS 也显著升高。对于 Ti6554 钛合金, 其体心立方结构的 β 相与面心立方结构的 α 相并存, 因此在低温环境下, 两相晶体学特征的差异导致 α 相的弹性各向异性显著增强。加载时, 晶体各向异性加剧了不同晶粒间的变形不协调性, 从而引发局部应力重新分配。从强化机制来看, Ti6554 钛合金中的 Al、Sn、Zr 等高固溶强化元素的存在, 导致其在低温下进一步促进了位错钉扎, 显著提升材料的强度与韧性^[35]。在材料塑性变形的初始弹性阶段, 若位错运动受到阻碍难以滑移, 则会导致局部区域出现显著的应力集中现象。为缓解这种应力状态, 材料需通过孪生机制或沿晶界滑移来重新分布应变能, 进而实现应力的释放与位错的进一步运动。

图 4 为材料的抗拉强度、屈服强度和延伸率随着温度变化的折线图。可以发现, Ti6554 钛合金的抗拉强度、屈服强度随着温度的降低逐渐升高, 而延伸率却逐渐下降。如图 4a 所示, 在测试范围内, 材料在 0 °C 时的屈服强度和抗拉强度最低, 分别为 962.11 MPa 和 980.09 MPa, 而在-180 °C 时, 两者达到最高值, 分别为 1 559.84 MPa 和 1 585.56 MPa, 表明在低温条件下, 合金的强度得到了显著提升。这种强度的增加可能是由于低温下材料内部的位错运动受到阻碍, 从而导致材料强度增加, 但是在-180 °C 下, 延伸率较低, 存在较高脆性风险^[36]。在-180 °C, 取得最小延伸率 10.15%, 相较于 0 °C 最大延伸率 17.96%, 下降了 7.81%, 如图 4b 所示。这意味着材料在强度提高的同时塑性有所降低^[36]。但是, 合金的塑性并非随着温度降低而单调递减, 在-90 °C 时, 其延伸率保持在 12.99%, 屈服强度和抗拉强度为 1 264.89 MPa 和 1 278.32 MPa, 呈现出高拉伸强度与优异延展性的理想组合。这表明合金在-90 °C 具有应用潜力^[10]。与 Ti-6Al-4V 合金相比, Ti6554 钛合金在-90 °C 时的屈服强度和抗拉强度最优^[37]。上述现象产生的原因为: 合金的位错滑移是一个热激活的扩散过程, 在低温环境下, 原子扩散变得困难, 此时晶格间摩擦力增大, 导致原子运动有限, 位错滑移的障碍显著增强, 导致位错滑移的临界分切应力 (CRSS) 显著升高^[5,10,35]。正是 CRSS 的大幅增加, 构成了材料低温强化效应的核心微观机制: 一方面, 它极大地增

加了位错启动滑移和维持滑移运动所需克服的能垒, 导致材料屈服强度和抗拉强度显著提升, 即材料抵抗塑性变形起始与持续的能力增强; 另一方面, CRSS 也严重限制了位错的可动性, 导致位错滑移距离缩短, 且位错协调变形机制难以进行, 最终严重削弱了材料的均匀塑性变形能力, 宏观上表现为延伸率与断面收缩率等塑性指标下降^[8]。




图 4 力学性能和延伸率变化折线图

Fig.4 Variations in mechanical properties and elongation: a) yield strength and tensile strength; b) elongation after fracture

2.2 加工硬化率

Ti6554 钛合金加工硬化率曲线如图 5 所示。可知, Ti6554 钛合金在不同温度和应变率下的硬化率曲线表现出非单调行为。加工硬化率随着应变量的增加呈现递减趋势。在真应变达到 0.09 之前, 加工硬化率的数值随着温度的降低而降低, 在 0.09 之后, 曲线呈现出明显的阶梯状下降趋势, 产生这一现象可能是因为存在平均尺寸约 2 μm 的超细晶, 孪生激活程度与晶粒尺寸存在反比关系^[38]。在-100 °C 以下, 低温导致原子热运动提供的能量不足, 导致热激活过程的效率减弱, 位错难以获得足够能量克服壁垒, 变形主导机制发生改变, 出现应力攀升^[5,10]。在 0~-90 °C, 变形机制以位错滑移和孪生为主, 当温度为-120~-180 °C 时, 层错能较高, 孪生启动的难度加大, 所以只发生了位错运动, 延伸率降低, 塑性变形阶段减少^[39]。




图5 Ti6554 钛合金加工硬化率曲线

Fig.5 Work hardening rate curve of Ti6554 titanium alloy

2.3 断口形貌

为了探究 Ti6554 钛合金在拉伸过程中的断裂机制,对不同状态下的拉伸样品断口形貌进行了表征与分析。如图 6a 所示,在 $-30\text{ }^{\circ}\text{C}$ 时, Ti6554 钛合金断口在低倍镜下呈明显颈缩变形,断面呈现梯形纤维区及双侧剪切唇,纤维区内轮廓在低倍下较为平坦,微观层面则呈低矮山岭状起伏,在高倍镜下观察到细小且均匀的等轴韧窝形貌,此特征验证了韧性断裂模式^[10]。如图 6b 所示, $-90\text{ }^{\circ}\text{C}$ 下断口形貌的剪切唇较 $-30\text{ }^{\circ}\text{C}$ 时减少 10%,且边缘呈现不规则形态,纤维区内出现放射状微裂纹,在高倍下可以看到断裂机制开始由韧性向脆性转变。图 6c 表明,在 $-180\text{ }^{\circ}\text{C}$ 时,低倍断口形貌兼具韧性与脆性断裂特征,在高倍下呈现解理面特征,表明材料断裂模式转变为混合断裂模式。Ti6554 钛合金的断裂机制呈现出温度效应:随实验温度下降,材料逐渐由韧性断裂过渡至脆韧混合断裂模式,此行为与低温条件下位错运动受阻及多种机制交互作用密切相关^[14,40]。

2.4 微观组织对低温力学性能的影响

图 7 为 Ti6554 钛合金在 $-30\text{ }^{\circ}\text{C}$ 和 $-180\text{ }^{\circ}\text{C}$ 拉伸变形区域的 EBSD 表征结果,拉伸方向如图 7a 和图 7b 所示。由图 7a 可知,在 $-30\text{ }^{\circ}\text{C}$ 的变形组织中存在具有特定取向差关系的界面,表明存在较大的塑性变形区,且同一晶粒内部变形区域的方向一致^[41-42],这体现为图 7c 中显示的欧拉角取向相近,欧拉角取向图(图 7c)进一步展示了该区域的取向特征与晶界分布。在 $-180\text{ }^{\circ}\text{C}$ 条件下的 EBSD 图中,图 7b 表现出显著的等轴晶粒微观结构且分布较为均匀,增加了变形抗力,导致应力值升高,同时降低了材料的延伸率。图 7c 显示, $-30\text{ }^{\circ}\text{C}$ 下变形区内存在取向相近的晶粒团,其内部产生了大量与基体取向不一致的区域,表明塑性影响区较大,这在一定程度上解释了 $-30\text{ }^{\circ}\text{C}$ 温度下延伸率相对较高的原因^[39]。如图 7d 所示,内部




图6 不同拉伸温度下的拉伸断口形貌

Fig.6 Tensile fracture surface morphologies at different temperatures

晶粒取向一致的区域增多,表明发生了晶格转动,此时变形以位错滑移为主导。KAM 值通常用于表征变形组织内部残余应变与储存能水平^[43]。图 7e 和图 7f 分别为 $-30\text{ }^{\circ}\text{C}$ 和 $-180\text{ }^{\circ}\text{C}$ 拉伸后断口附近的 KAM 图, KAM 图像的蓝色区域代表低密度位错区,绿色区域则代表高密度位错区。 $-30\text{ }^{\circ}\text{C}$ 的 KAM 图颜色分布不均匀,晶界、孪晶界和晶粒团界面处的 KAM 值较高,表明这些区域位错密度高、储存能大; $-180\text{ }^{\circ}\text{C}$ 的 KAM 图颜色分布相对均匀,晶粒团内部位错密度低且均匀,界面处 KAM 值高。这表明在 $-30\text{ }^{\circ}\text{C}$ 的变形过程中,当位错运动受阻时, Ti6554 钛合金通过孪晶变形协调塑性应变,孪晶界成为位错积累和相互作用的重要场所;而在 $-180\text{ }^{\circ}\text{C}$ 时,位错滑移成为主导机制,位错在晶粒内部更均匀地分布和存储。图 7g 和图 7h 分别是 $-30\text{ }^{\circ}\text{C}$ 和 $-180\text{ }^{\circ}\text{C}$ 的取向差图,由图 7g 可知,在 $-30\text{ }^{\circ}\text{C}$ 有 3 个峰值,分别位于 5° 、 40° 和 85° 。在 $5^{\circ}\sim 10^{\circ}$ 范围内,峰值是为 $5.5^{\circ}/\langle 0001 \rangle \alpha$,对应小角度晶界;而在 $25^{\circ}\sim 45^{\circ}$ 内,最高峰值是 $40.5^{\circ}/\langle 11\bar{2}0 \rangle$ 取向关系,属于压缩孪晶界;在 $80^{\circ}\sim 90^{\circ}$ 范围内,最高峰值为 $86.5^{\circ}/\langle 11\bar{2}0 \rangle \alpha$,表现为拉伸孪晶界。而由图 7h 可知, $-180\text{ }^{\circ}\text{C}$ 有 1 个峰值,位于 5° 。在 $5^{\circ}\sim 10^{\circ}$ 内,峰值为 $5.5^{\circ}/\langle 0001 \rangle \alpha$,同样为小角度晶界。由此可知,在 $-30\text{ }^{\circ}\text{C}$ 与 $-180\text{ }^{\circ}\text{C}$,合金拉伸性能的差异本质上




图 7 Ti6554 钛合金断口附近组织 EBSD 分析

Fig.7 EBSD analysis of the microstructure near the fracture surface of Ti6554 titanium alloy: a) BC map at $-30\text{ }^{\circ}\text{C}$; b) BC map at $-180\text{ }^{\circ}\text{C}$; c) Euler-angle map acquired at $-30\text{ }^{\circ}\text{C}$; d) Euler-angle map acquired at $-180\text{ }^{\circ}\text{C}$; e) KAM map at $-30\text{ }^{\circ}\text{C}$; f) KAM map at $-180\text{ }^{\circ}\text{C}$; g) misorientation at $-30\text{ }^{\circ}\text{C}$; h) misorientation at $-180\text{ }^{\circ}\text{C}$

是由于温度变化引起层错能改变。在 $-30\text{ }^{\circ}\text{C}$ 时, 较低的层错能有效促进了全位错分解为不全位错, 从而激活了孪生变形, 这在取向差分析中表现为 $40.5^{\circ}/\langle 11\bar{2}0 \rangle$ 的压缩孪晶与 $86.5^{\circ}/\langle 11\bar{2}0 \rangle$ 的拉伸孪晶; 孪生与位错滑移的协同作用能够更有效地协调塑性应变, 延缓颈缩和裂纹萌生, 因此表现出较高的断后延伸率 (13.54%)。与之相反, 在 $-180\text{ }^{\circ}\text{C}$ 的条件下, 层错能升高, 全位错难以分解为不全位错, 抑制了孪晶的形核与扩展, 致使塑性变形几乎完全由位错滑移主导。该单一机制应变协调能力有限, 易导致局部应力集中和早期断裂, 因此延伸率较低 (10.15%)。综上所述, 在 $-30\text{ }^{\circ}\text{C}$ 下, 更优的塑性源于其满足了孪生变形所需

的热-力学条件, 使孪晶得以形核并充分长大; 而在 $-180\text{ }^{\circ}\text{C}$ 下, 因形核能垒过高, 体系未能积累足够的能量以驱动有效的孪生过程^[10,39,44]。

2.5 流动应力预测

2.5.1 支持向量回归-粒子群优化算法模型

当前, 粒子群优化算法 (Particle Swarm Optimization, PSO) 以其操作流程直观、参数配置相对较少、快速收敛以及展现出显著的全局寻优效能而著称。本研究采纳粒子群优化 (PSO) 算法对支持向量回归 (SVR) 模型的参数进行全局优化搜索, 通过识别并应用最佳参数, 对数据集进行基于 SVR 的回归

模型训练,获得预测的流动应力,并使用 Python 编程实现。如表 3 所示,在应用 PSO 优化 SVR 回归模型参数时,优化参数设置如下:数据集包括 3 个输入量,分别是真应变、应变速率和温度与一个输出量流动应力。本组数据总共 19 200 组,通过试凑法选取其中 70% (13 440 组) 的数据用于训练模型, 15% (2 880 组) 的数据则作为测试集, 15% (2 880 组) 的数据作为验证集。均值填充缺失值,对数据进行标准化,采用了径向基函数 (Radial Basis Function, RBF) 作为核函数。在粒子群优化算法中,认知学习因子为 0.5, 社会学习因子为 0.3, 惯性权重为 0.9, 粒子数目为 10, 最大迭代次数为 100, 不敏感损失函数 ζ 的取值范围为 [0,0.1], 惩罚因子 C 的取值范围为 [0,100], 核参数 g 的取值范围为 [0,0.1]^[16,27,45-46]。通过寻优过程,获得最优的不敏感损失函数、惩罚因子和核参数,如表 3 所示。

表 3 PSO-SVR 优化参数设置

Tab.3 Parameter settings for PSO-SVR optimization

Parameter	Value
Particle number	10
Maximum iteration number	100
Insensitive parameter ζ	0.039
Penalty factor C	881.719
Kernel parameter g	0.099

图 8 为 6 个不同温度下学习模型所预测的 Ti6554 钛合金应力值与其对应的实验应力值之间的对应关系。根据所呈现的图表分析,实验数据与预测结果呈现出较高的一致性,聚集于模型预测中心线周围,这有力地证实了支持向量机与超参数优化集成策略在构建模型时的较强预测能力。此结果进一步巩固了支持向量机在应对小规模数据集及非线性特征空间时展现出的优越性。




图 8 PSO-SVM 预测应力与实验应力的关系图

Fig.8 Correlation between PSO-SVM predicted stress and experimental stress

2.5.2 误差反向传播神经网络模型

误差反向传播神经网络 (Error Back-Propagation Neural Network, EBP) 由一系列非线性变换节点构成,属于前馈型网络体系。本组数据总共 19 200 组,通过试凑法选取其中 70% (13 440 组) 的数据用于训练模型, 15% (2 880 组) 的数据作为测试集, 15% (2 880 组) 的数据作为验证集^[47]。EBP 神经网络通过试凑法确定了 3 个隐含层^[48],每个隐含层神经元个数分别为 64、32、8,其中隐含层的输入神经元个数为 3,对应输入特征为真应变、温度和应变速率。输出神经元个数为 1,对应输出目标为流动应力。采用均值填充缺失值,数据标准化,数据集中训练集和测试集比值为 7:3。在激活函数方面,隐含层激活函数采用了 relu 函数。采用 adam 算法进行优化,正则化参数默认值,设置自适应学习率一阶为 0.9 和二阶为 0.999,动量因子为 0.95,初始学习率为 0.000 5,最大迭代次数为 200。在误差反向传播过程中,计算损失函数值以评估模型预测值与实验值的差距,同时引入动量项加速收敛过程,以及自适应学习率调整机制以优化权重更新策略,从而提升模型的学习效率和泛化能力。动量机制通过聚合过往梯度信息促进加速收敛过程,而自适应学习率策略则依据损失函数的变化动态调整个别参数的学习速率,以规避振荡现象。

图 9 为不同温度条件下 EBP 神经网络模型所预测的 Ti6554 钛合金应力值与其对应的实验真应力值之间的对比关系。如图 9 所示,实验观测值与预测值呈现出高度一致性,各个数据点都均紧邻于中心线分布,并未出现较大偏差。通过集成动量项与自适应学习率调整机制,EBP 神经网络展现出在维持高水平预测准确性的同时,大幅缩减训练周期效能的特性,因此特别适用于大规模数据集及复杂模型的高效训练任务。这充分揭示了所采用的神经网络模型在构建模型预测性能方面的优越性。




图 9 EBP 预测应力与实验应力的关系图

Fig.9 Relationship between EBP predicted stress and experimental stress

2.5.3 支持向量回归-粒子群优化算法模型与误差反向传播神经网络模型对比

对采用粒子群优化支持向量回归(Particle Swarm Optimization-Enhanced Support Vector Regression, PSO-SVR)构建的机器学习模型预测的真应力真应变与实验值进行了对比分析,如图 10a 和图 10b 所示。其中以特定的符号形状描绘了预测结果,符号越接近曲线,表明预测值越准确。如图 10a 所示,在 0 °C 条件下,模型的预测值和实际值高度吻合。图 10b 为更低温度下的预测效果:在-30 °C 和-60 °C 时,PSO-SVR 模型能够有效捕捉材料的非线性力学响应,对应力参数实现了精确预测。然而,在-90 °C 下,应力出现突变,其非线性响应超过模型的核函数的拟合能力范围,导致从屈服强度开始至塑性变形初期阶段,预测值和实际值产生较大的偏差。但在塑性变形后半段,预测值和实际值实现了高度一致性。在-120 °C 下,材料加工硬化率升高,导致预测结果在材料塑性变形过程中的中间阶段呈现出低于实际观测值的趋势。在-150 °C 和-180 °C 条件下,真应力-真应变曲线趋于平缓,实验值和预测值的趋势走向相吻合。

EBP 神经网络预测的真应力-真应变与实验测得

的真应力-真应变对比如图 10c 和图 10d 所示,其中符号形状代表不同温度下 EBP 神经网络的预测值。由图 10c 可知,0 °C 下的预测值和实际值表现出高度一致性。图 10d 表明,在-30~-150 °C 温度范围内,预测值与实验值在抗拉强度和屈服强度等关键力学性能指标上均展现出良好的一致性趋势。然而,当温度降至-180 °C 时,在屈服强度后阶段进入塑性变形区时,实际观测到的应力值呈现出持续降低的趋势,而预测值为逐渐增长的趋势。

由图 11 可知,在 0、-30、-60、-180 °C 下 EBP 模型与 PSO-SVR 模型的 RMSE 差距不大,在-90、-120、-150 °C 温度下,EBP 的拟合能力更强。EBP 模型的波动范围较小,整体表现更稳健,表现出优异的低温拟合能力。相比之下,PSO-SVR 模型的 RMSE 波动范围大,且在-90 °C 和-120 °C 等中间温度区,预测值具有不稳定性。计算平均 RMSE 可知,EBP 模型的为 4.01 MPa,远低于 PSO-SVR 模型的 11.12 MPa,进一步验证了 EBP 模型综合性能的优越性及其在处理复杂非线性关系时更强的适应性和鲁棒性。分析其原因,PSO-SVR 模型的性能高度依赖于核函数选择和超参数优化,对于本文涉及的高度复杂、非线性的多温度




图 10 预测流动应力与实验流动应力的关系图

Fig.10 Correlation between predicted and experimental flow stress: a) comparison between PSO-SVR predicted and experimental values at 0 °C; b) comparison between PSO-SVR predicted and experimental values at -30, -60, -90, -120, -150, and -180 °C; c) comparison between EBP predicted and experimental values at 0 °C; d) comparison between EBP predicted and experimental values at -30, -60, -90, -120, -150, and -180 °C





图 11 PSO-SVR 和 EBP 的 RMSE 比较

Fig.11 Comparison of RMSE between PSO-SVR and EBP

区间数据,其泛化能力表现不足。相比之下,EBP 模型通过其多层结构实现非线性自适应学习机制,在处理此类多温度区间、强非线性关系的流动应力预测任务时展现出更强的适应性。

PSO-SVR 和 EBP 的 R^2 比较结果如图 12 所示。由统计分析可知,EBP 模型和 PSO-SVR 模型在不同低温下的决定系数存在显著差异。EBP 模型的 R^2 在 0~-150 °C 均保持在 0.98~0.95,在 -60 °C 和 -180 °C 时为 0.95。相比之下,PSO-SVR 模型的决定系数在 0~-60 °C 范围内从 0.94 逐渐下降至 0.92,在 -90 °C 时降至 0.83,在 -120 °C 时为 0.79,在 -150 °C 时进一步降至最低值 0.72,虽然在 -180 °C 时回升至 0.87,但其整体稳定性明显低于 EBP 模型的。上述决定系数的变化趋势清晰地揭示了温度对模型预测精度的影响以及模型的鲁棒性差异:EBP 模型的 R^2 在整个测试温度区间总体趋于平缓,波动极小;而 PSO-SVR 模型的决定系数则表现出较大的波动性,特别是在 -90~-150 °C 区间,出现急剧下降趋势。EBP 模型在 -180 °C 仍能维持较高的决定系数,表明其对材料在极低温条件下复杂非线性行为的捕捉能力更强。

PSO-SVR 模型和 EBP 模型的 MAE 比较结果如表 4 所示。从各温度下的 MAE 值以及平均值来看,EBP 神经网络模型整体表现优于 PSO-SVR 支持向量机模型。PSO-SVR 模型的 MAE 平均值达到 9.024 MPa,而 EBP 神经网络模型的平均 MAE 为 2.067 MPa,这表明在整个温度范围内,EBP 模型的预测准确性更高。由表 4 可知,在 0、-30 和 -60 °C 下,PSO-SVR 模型的

图 12 PSO-SVR 和 EBP 的 R^2 比较Fig.12 Comparison of R^2 between PSO-SVR and EBP

MAE 误差相对较小,在这 3 个温度下模型的预测较为准确,与实际值较为接近。但在 -90、-120、-150 °C 时,MAE 值急剧上升,在 -120 °C 和 -150 °C 时分别达到 18.914 MPa 和 18.067 MPa,表明在这些温度区间,模型的预测误差较大,预测性能出现明显下降。而表 4 中,EBP 模型各个温度下的 MAE 值相对较为稳定,其最大值为 6.133 MPa,最小值为 0.902 MPa,在不同温度场景下均能保持相对稳定的预测精度。总的来说,EBP 模型在整体预测精度和不同温度场景下的稳定性方面均优于 PSO-SVR 模型,对于这种需要在不同温度条件下进行预测的任务,EBP 模型是一个更合适的选择。而 PSO-SVR 模型在部分温度区间如 0、-30、-60 °C 虽然也能达到较低的 MAE,但在多数温度区间尤其是极端温度下预测误差较大,其适用性相对较弱。

从 3 个误差分析可得,PSO-SVR 模型在 -90~-150 °C 区间出现的预测精度显著下降,可能源于在该温区,材料本构关系具有更强的非线性特征,而核函数映射能力有限,导致对复杂应力-温度匹配描述不足。此外,超参数优化过程可能陷入局部最优,削弱了模型在非训练区间的泛化能力。相比之下,EBP 模型凭借其多层非线性变换结构与自适应权重调整机制,能够更精细地捕捉不同温区下材料变形行为的连续演化规律,因而表现出更为一致的预测稳定性。结合实际可得,在极低温条件下,材料往往经历相变、位错运动机制转变等微观结构演化,导致流动应力行为呈现显著非单调性与突变特征。EBP 模型在 -180 °C 增加了权重之后保持了较高精度,说明其在

表 4 PSO-SVR 模型和 EBP 模型的 MAE 比较

Tab.4 MAE comparison between PSO-SVR model and EBP model

Model name	0 °C	-30 °C	-60 °C	-90 °C	-120 °C	-150 °C	-180 °C	Sum
PSO-SVR	3.01	2.974	2.958	10.923	18.914	18.067	6.32	9.024
EBP	1.24	1.371	1.652	1.56	1.161	0.902	6.133	2.067

一定程度上学习到了此类低温物理机制; 而 PSO-SVR 模型在极端温度区间的波动, 反映出其对材料深层物理规律建模能力的不足。未来研究可结合晶体塑性理论或引入物理约束项或调整权重, 进一步增强模型对低温变形机理的显式建模能力, 提升预测结果的物理可信度与外推可靠性。

3 结论

1) 在低温拉伸实验中, Ti6554 钛合金的低温力学性能并非单调变化, 在 $-90\text{ }^{\circ}\text{C}$ 呈现高强度与良好塑性的最佳匹配, 其屈服强度为 $1\ 264.89\text{ MPa}$, 延伸率为 12.99% 。当拉伸温度从 $-90\text{ }^{\circ}\text{C}$ 升至 $-120\text{ }^{\circ}\text{C}$ 时, 屈服强度发生 197 MPa 的跃升, 同时伴随塑性急剧下降。

2) 在 $-30\text{ }^{\circ}\text{C}$ 下, 较低的层错能有利于孪晶的激活, 此时主要为位错滑移和孪晶的共同协调作用。当温度为 $-180\text{ }^{\circ}\text{C}$ 时, 层错能升高, 导致孪晶被抑制, 变形转变为以位错滑移为主, 引发了提前断裂。从孪生结合滑移的混合机制转变到以滑移主导, 是导致宏观性能突变的本质原因, 深化了对 $\beta\text{-Ti}$ 合金低温变形的理解。

3) EBP 神经网络模型在预测多温度区间内的材料流动应力方面, 凭借其多层非线性自适应学习机制, 在 RMSE(平均 4.01 MPa)、MAE(平均 2.067 MPa) 及决定系数 R^2 (普遍高于 0.95) 等关键指标的预测上均显著优于 PSO-SVR 模型 (RMSE 平均 11.12 MPa , MAE 平均 9.024 MPa , R^2 波动较大), 尤其在 $-90\sim -150\text{ }^{\circ}\text{C}$ 及 $-180\text{ }^{\circ}\text{C}$ 等关键温度点, 展现出更优异的预测精度、稳定性。可见基于 EBP 神经网络建立的模型预测精度高, 相关性好。

参考文献:

[1] LI C M, LUO H J, WEI M G, et al. Research on Hot Workability and Deformation Mechanism of As-Extruded Ti-6554 Alloy over a Broad Temperature Range[J]. Journal of Alloys and Compounds, 2025, 1010: 177055.

[2] 孟亚飞, 王庆敏, 武川, 等. Ti6554 钛合金连续孔型轧制过程微观组织演化和力学性能研究[J]. 精密成形工程, 2025, 17(8): 12-24.

MENG Y F, WANG Q M, WU C, et al. Microstructure Evolution and Mechanical Properties of the Ti6554 Titanium Alloy during Continuous Hole Rolling Process[J]. Journal of Netshape Forming Engineering, 2025, 17(8): 12-24.

[3] 彭志伟, 武川, 王圆圆, 等. Ti6554 钛合金 β 相区动态再结晶元胞自动机模拟[J]. 塑性工程学报, 2025, 32(2): 163-171.

PENG Z W, WU C, WANG Y Y, et al. Cellular Automa-

ton Simulation of Dynamic Recrystallization in β Phase Region of Ti6554 Titanium Alloy[J]. Journal of Plasticity Engineering, 2025, 32(2): 163-171.

- [4] LU Z C, ZHANG X H, JI W, et al. Investigation on the Deformation Mechanism of Ti-5Al-2.5Sn ELI Titanium Alloy at Cryogenic and Room Temperatures[J]. Materials Science and Engineering: A, 2021, 818: 141380.
- [5] ZANG M C, NIU H Z, YU J S, et al. Cryogenic Tensile Properties and Deformation Behavior of a Fine-Grained near Alpha Titanium Alloy with an Equiaxed Microstructure[J]. Materials Science and Engineering: A, 2022, 840: 142952.
- [6] HAO F, XIAO J F, FENG Y, et al. Tensile Deformation Behavior of a Near- α Titanium Alloy Ti-6Al-2Zr-1Mo-1V under a Wide Temperature Range[J]. Journal of Materials Research and Technology, 2020, 9(3): 2818-2831.
- [7] XU Y L, ZHANG B B. Effects of Hydrogen as a Solid Solution Element on the Deformation Behavior of a Near-Alpha Titanium Alloy[J]. Materials Science and Engineering: A, 2021, 815: 141269.
- [8] YAO K, XIN S W, YANG Y, et al. Ultrahigh Cryogenic Strength and Exceptional Ductility at 20 K in a TWIP Ti-15Mo Alloy[J]. Scripta Materialia, 2022, 213: 114595.
- [9] DI I S, BRIOTTET L, RAUCH E F, et al. Plastic Deformation, Damage and Rupture of PM Ti-6Al-4V at 20 K under Monotonic Loading[J]. Acta Materialia, 2007, 55(1): 105-118.
- [10] ZANG M C, NIU H Z, ZHANG H R, et al. Cryogenic Tensile Properties and Deformation Behavior of a Superhigh Strength Metastable Beta Titanium Alloy Ti-15Mo-2Al[J]. Materials Science and Engineering: A, 2021, 817: 141344.
- [11] HUANG Z W, JIN S B, ZHOU H, et al. Evolution of Twinning Systems and Variants during Sequential Twinning in Cryo-Rolled Titanium[J]. International Journal of Plasticity, 2019, 112: 52-67.
- [12] HUANG S X, ZHAO Q Y, ZHAO Y Q, et al. Toughening Effects of Mo and Nb Addition on Impact Toughness and Crack Resistance of Titanium Alloys[J]. Journal of Materials Science & Technology, 2021, 79: 147-164.
- [13] 戴进财, 闵小华, 辛社伟, 等. 间隙元素 O 对 β 型 Ti-15Mo 合金超低温力学性能的影响[J]. 金属学报, 2025, 61(2): 243-252.
- DAI J C, MIN X H, XIN S W, et al. Effect of Interstitial Element O on Cryogenic Mechanical Properties in β -Type Ti-15Mo Alloy[J]. Acta Metallurgica Sinica, 2025, 61(2): 243-252.
- [14] 郑壮壮, 陆子川, 杨建辉, 等. CT1400 低温钛合金的显微组织与力学性能[J]. 材料工程, 2024, 52(11): 125-132.
- ZHENG Z Z, LU Z C, YANG J H, et al. Microstructure and Mechanical Properties of CT1400 Cryogenic Titanium Alloy[J]. Journal of Materials Engineering, 2024,

- 52(11): 125-132.
- [15] 夏天, 高志玉, 赵斐, 等. 金属材料塑性本构模型建立研究进展[J]. 塑性工程学报, 2024, 31(9): 23-35.
XIA T, GAO Z Y, ZHAO F, et al. Research Progress on Establishing of Plastic Constitutive Models for Metal Materials[J]. Journal of Plasticity Engineering, 2024, 31(9): 23-35.
- [16] 施文鹏, 孙岑花, 李佳俊, 等. 基于人工智能神经网络智能算法的 9310 钢本构模型优化[J]. 精密成形工程, 2024, 16(3): 171-180.
SHI W P, SUN C H, LI J J, et al. 9310 Steel Constitutive Model Optimization Based on Artificial Neural Network Intelligent Algorithm[J]. Journal of Netshape Forming Engineering, 2024, 16(3): 171-180.
- [17] 周潼, 程军, 王克鲁, 等. Ti_2AlNb 基金热变形行为及加工图研究[J]. 中国机械工程, 2025, 36(11): 2757-2765.
ZHOU T, CHENG J, WANG K L, et al. Hot Deformation Behavior and Processing Maps of Ti_2AlNb -Based Alloys[J]. China Mechanical Engineering, 2025, 36(11): 2757-2765.
- [18] 王新云, 唐学峰, 余国卿, 等. 基于深度学习的塑性变形理论建模研究进展[J]. 塑性工程学报, 2024, 31(4): 92-116.
WANG X Y, TANG X F, YU G Q, et al. Research Progress on Theoretical Modeling of Plastic Deformation Based on Deep Learning[J]. Journal of Plasticity Engineering, 2024, 31(4): 92-116.
- [19] 唐学峰, 王志洲, 冯仪, 等. 基于机器学习的 TC18 钛合金起落架锻造成形工艺智能优化[J]. 塑性工程学报, 2024, 31(4): 254-266.
TANG X F, WANG Z Z, FENG Y, et al. Intelligent Optimization of Forging Forming Process of TC18 Titanium Alloy Landing Gear Based on Machine Learning[J]. Journal of Plasticity Engineering, 2024, 31(4): 254-266.
- [20] 赵德望, 刘汉杰, 赵延广, 等. 基于数理与机器学习的 ZTC 钛合金塑性本构模型[J]. 中国有色金属学报, 2025, 35(10): 3539-3551.
ZHAO D W, LIU H J, ZHAO Y G, et al. Plastic Constitutive Model of ZTC4 Titanium Alloy Based on Theoretical Modeling and Machine Learning[J]. The Chinese Journal of Nonferrous Metals, 2025, 35(10): 3539-3551.
- [21] PENG Z S, JI H C, PEI W C, et al. Constitutive Relationship of TC4 Titanium Alloy Based on Back Propagating (BP) Neural Network (NN)[J]. Metalurgija, 2021, 60(3/4): 277-280.
- [22] 武鹏飞, 肖旭彤, 娄燕山, 等. 不同温度下 Mg-Gd-Y 稀土镁合金的变形行为表征[J]. 塑性工程学报, 2022, 29(6): 134-140.
WU P F, XIAO X T, LOU Y S, et al. Characterization of Deformation Behavior of Mg-Gd-Y Rare Earth Magnesium Alloy at Different Temperatures[J]. Journal of Plasticity Engineering, 2022, 29(6): 134-140.
- [23] LI S J, CHEN W N, BHANDARI K S, et al. Flow Behavior of AA5005 Alloy at High Temperature and Low Strain Rate Based on Arrhenius-Type Equation and back Propagation Artificial Neural Network (BP-ANN) Model[J]. Materials, 2022, 15(11): 3788.
- [24] 赵文娟, 丁桦, 周舸, 等. TC21 合金超塑性本构关系的 BP 神经网络模型[J]. 锻压技术, 2009, 34(4): 138-142.
ZHAO W J, DING H, ZHOU G, et al. Constitutive Relationship Model of TC21 Alloy during Superplastic Deformation Based on BP Artificial Neural Network[J]. Forging & Stamping Technology, 2009, 34(4): 138-142.
- [25] SONG S H. A Comparison Study of Constitutive Equation, Neural Networks, and Support Vector Regression for Modeling Hot Deformation of 316L Stainless Steel[J]. Materials, 2020, 13(17): 3766.
- [26] HUSSAIN A, SAKHAEI A H, SHAFIEE M. Machine Learning-Based Constitutive Modelling for Material Non-Linearity: A Review[J]. Mechanics of Advanced Materials and Structures, 2024: 1-19.
- [27] LIU Y F, FENG Y D, LIU Q B, et al. Prediction of Flow Stress in Mg-3Dy Alloy Based on Constitutive Equation and PSO-SVR Model[J]. Materials Research Express, 2024, 11(5): 056513.
- [28] JANG D P, FAZILY P, YOON J W. Machine Learning-Based Constitutive Model for J2-Plasticity[J]. International Journal of Plasticity, 2021, 138: 102919.
- [29] QIAO L, DENG Y, WANG Y, et al. A Comparative Study on Arrhenius Equations and BP Neural Network Models to Predict Hot Deformation Behaviors of a Hypereutectoid Steel[J]. IEEE Access, 2020, 8: 68083-68090.
- [30] 王宇航, 罗拴谋, 董显娟, 等. 基于物理参数和 BP 神经网络的 9310 钢本构模型研究[J]. 塑性工程学报, 2024, 31(8): 117-124.
WANG Y H, LUO S M, DONG X J, et al. Research on Constitutive Model of 9310 Steel Based on Physical Parameters and BP Neural Network[J]. Journal of Plasticity Engineering, 2024, 31(8): 117-124.
- [31] 张开铭, 温余远, 王克鲁, 等. Ti-22Al-24Nb 合金热变形行为及本构关系[J]. 塑性工程学报, 2022, 29(10): 208-215.
ZHANG K M, WEN Y Y, WANG K L, et al. Hot Deformation Behavior and Constitutive Relation of Ti-22Al-24Nb Alloy[J]. Journal of Plasticity Engineering, 2022, 29(10): 208-215.
- [32] CAI Z M, JI H C, PEI W C, et al. Constitutive Model of 3Cr23Ni8Mn3N Heat-Resistant Steel Based on back Propagation (BP) Neural Network (NN)[J]. Metalurgija, 2019, 58: 191-195.
- [33] LIU J T, CHANG H B, HSU T Y, et al. Prediction of the Flow Stress of High-Speed Steel during Hot Deformation Using a BP Artificial Neural Network[J]. Journal of Materials Processing Technology, 2000, 103(2): 200-205.
- [34] 于清波, 李建明, 杨月冰, 等. TA15 钛合金低温力学

- 性能及 J-C 本构模型的研究[J]. 工具技术, 2024, 58(4): 77-83.
- YU Q B, LI J M, YANG Y B, et al. Study on Cryogenic Mechanical Properties and J-C Constitutive Model of TA15 Titanium Alloy[J]. Tool Engineering, 2024, 58(4): 77-83.
- [35] 张云波. 典型钛合金极低温下的变形机理研究[D]. 西安: 西安理工大学, 2024.
- ZHANG Y B. Study on Deformation Mechanism of Typical Titanium Alloy at Extremely Low Temperature[D]. Xi'an: Xi'an University of Technology, 2024.
- [36] 李佳怡. 双相钛合金超低温塑性变形行为与机理研究[D]. 北京: 北方工业大学, 2024.
- LI J Y. Study on Ultra-Low Temperature Plastic Deformation Behavior and Mechanism of Dual-Phase Titanium Alloy[D]. Beijing: North China University of Technology, 2024.
- [37] HU J W, CHEN X, WANG Y S, et al. Mechanical Properties and Flow Stress Constitutive Relationship of Ti-6Al-4V Alloy with Equiaxed Microstructure at Cryogenic Temperatures[J]. Chinese Journal of Aeronautics, 2025, 38(1): 103238.
- [38] ZHU Y T, LIAO X Z, WU X L. Deformation Twinning in Nanocrystalline Materials[J]. Progress in Materials Science, 2012, 57(1): 1-62.
- [39] NIU H Z, LIU S, ZANG M C, et al. Anomalous Strain Rate Dependence of Ultra-Low Temperature Strength and Ductility of an Electron Beam Additively Manufactured near Alpha Titanium Alloy[J]. Journal of Materials Science & Technology, 2024, 198: 44-55.
- [40] NAYAN N, SINGH G, ANTONY P T, et al. Cryogenic Mechanical Properties of Warm Multi-Pass Caliber-Rolled Fine-Grained Titanium Alloys: Ti-6Al-4V (Normal and ELI Grades) and VT14[J]. Metallurgical and Materials Transactions A, 2018, 49(1): 128-146.
- [41] SHIN S, ZHU C Y, VECCHIO K S. Observations on {332} Twinning-Induced Softening in Ti-Nb Gum Metal[J]. Materials Science and Engineering: A, 2018, 724: 189-198.
- [42] LEI L, ZHU Q W, ZHAO Q Y, et al. Low-Temperature Impact Toughness and Deformation Mechanism of CT20 Titanium Alloy[J]. Materials Characterization, 2023, 195: 112504.
- [43] 赵玥滔. TC4 钛合金低温变形组织与性能研究[D]. 哈尔滨: 哈尔滨理工大学, 2023.
- ZHAO Y T. Study on Microstructure and Properties of TC4 Titanium Alloy Deformed at Low Temperature[D]. Harbin: Harbin University of Science and Technology, 2023.
- [44] GUO M Q, ZHANG Y, ZHOU C, et al. The Transition from Strain Rate Insensitivity to Sensitivity of Ti-6Al-4V Alloys Deformed at Cryogenic Temperature[J]. Materials Science and Engineering: A, 2024, 902: 146627.
- [45] 梁强, 张贤明, 李平, 等. 基于修正 Arrhenius 模型和 SVR-PSO 模型的 HNi55-7-4-2 合金高温本构模型的对比[J]. 材料热处理学报, 2020, 41(8): 157-165.
- LIANG Q, ZHANG X M, LI P, et al. Comparative of High-Temperature Constitutive Model of HNi55-7-4-2 Alloy Based on Modified Arrhenius Model and SVR-PSO Model[J]. Transactions of Materials and Heat Treatment, 2020, 41(8): 157-165.
- [46] 梁强, 张贤明, 李平, 等. 基于修正 Arrhenius 模型和 SVR-PSO 模型的 HNi55-7-4-2 合金高温本构模型的对比[J]. 材料热处理学报, 2020, 41(8): 157-165.
- LIANG Q, ZHANG X M, LI P, et al. Comparative of High-Temperature Constitutive Model of HNi55-7-4-2 Alloy Based on Modified Arrhenius Model and SVR-PSO Model[J]. Transactions of Materials and Heat Treatment, 2020, 41(8): 157-165.
- [47] 朱鹏, 冯玮. 基于 BP 神经网络的 15Cr14Co12Mo5Ni2 齿轮钢本构模型建立及热加工图研究[J]. 塑性工程学报, 2025, 32(8): 177-186.
- ZHU P, FENG W. Research on Establishment of Constitutive Model and Hot Processing Map of 15Cr14Co12Mo5Ni2 Gear Steel Based on BP Neural Network[J]. Journal of Plasticity Engineering, 2025, 32(8): 177-186.
- [48] 姜淑梅, 李一明, 李鑫, 等. 基于 BP 神经网络和 Arrhenius 本构模型的石墨烯/7075 复合材料热变形行为[J]. 吉林大学学报(工学版), 2024, 54(5): 1237-1245.
- LOU S M, LI Y M, LI X, et al. Thermal Deformation Behavior of Graphene Nanosheets Reinforced 7075Al Based on BP Neural Network and Arrhenius Constitutive Equation[J]. Journal of Jilin University (Engineering and Technology Edition), 2024, 54(5): 1237-1245.